

# Notas del curso CA-403

I Ciclo 2020

## Instrucciones de uso

Este es un archivo de latex normal, salvo que se le pueden agregar códigos de R.


Para hacerlo solo debe encerrar su código con lo siguiente comandos.

```
<<>>=  
Su código acá.  
@
```

Algunas recomendaciones iniciales:

- Tratemos de ser ordenados con el texto y el código. Recuerden que esto será usado por ustedes en el examen.
- No usen comandos propios (`newcommand`) ya que eso solo haría más difícil que los compañeros puedan editar su trabajo.
- El documento es colaborativo, por lo que está bien editar o escribir “encima” de otro compañero, siempre y cuando esto sea para mejorar el texto.

Creo en el buen juicio de cada uno para hacer estas notas lo mejor posible.



# 1 Histograma

El histograma es una de las estructuras básicas en estadística. Básicamente con este objeto se puede visualizar la distribución de los datos sin tener conocimiento previo de los mismos.


## 1.1 Construcción Estadística

Suponga que  $X_1, X_2, \dots, X_n$  proviene de una distribución desconocida.

- Seleccione un origen  $x_0$  y divida la línea real en *segmentos*.

$$B_j = [x_0 + (j - 1)h, x_0 + jh) \quad j \in \mathbb{Z}$$

- Cuento cuántas observaciones caen en cada segmento.  $n_j$ .




- Cuento la frecuencia por el tamaño de muestra  $n$  y el ancho de banda  $h$ .

$$f_j = \frac{n_j}{nh}$$

- Dibuje el histograma.

$$\sum f_j = 1$$



Formalmente el histograma es el

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n \sum_j I(X_i \in B_j) I(x \in B_j),$$

donde  $I$  es la indicadora.


## 1.2 Construcción probabilística

Denote  $m_j = jh - h/2$  el centro del segmento,

$$\mathbb{P}\left(X \in \left[m_j - \frac{h}{2}, m_j + \frac{h}{2}\right)\right) = \int_{m_j - \frac{h}{2}}^{m_j + \frac{h}{2}} f(u) du \approx \underline{\underline{f(m_j)h}}$$

Esto se puede aproximar como

Desconocida



$$\mathbb{P}\left(X \in \left[m_j - \frac{h}{2}, m_j + \frac{h}{2}\right)\right) \approx \frac{1}{n} \# \left\{ X \in \left[m_j - \frac{h}{2}, m_j + \frac{h}{2}\right)\right\}$$

Acomodando un poco la expresión

$$\hat{f}_h(m_j) = \frac{1}{nh} \# \left\{ X \in \left[m_j - \frac{h}{2}, m_j + \frac{h}{2}\right)\right\}$$

### 1.3 Propiedades estadísticas

Suponga que  $x_0 = 0$  y que  $x \in B_j$  fijo, entonces

$$\hat{f}_h(m_j) = \frac{1}{nh} \sum_{i=1}^n I(X_i \in B_j)$$

#### 1.3.1 Sesgo

El cálculo del sesgo es el

$$\text{Bias}(\hat{f}_h) = \mathbb{E}[\hat{f}_h] - f(x)$$

$$\begin{aligned} \mathbb{E}[\hat{f}_h(m_j)] &= \frac{1}{nh} \sum_{i=1}^n \mathbb{E}[I(X_i \in B_j)] \\ &= \frac{1}{nh} n \mathbb{E}[I(X_i \in B_j)] \end{aligned}$$

$I(X_i \in B_j)$  es una indicadora con probabilidad de 1 de  $\int_{(j-1)h}^h f(u) du$  y 0 sino.

Entonces

$$\mathbb{E}[I(X_i \in B_j)] = \mathbb{P}(I(X_i \in B_j) = 1) = \int_{(j-1)h}^h f(u) du.$$

Entonces,

$$\mathbb{E}[\hat{f}_h(m_j)] = \frac{1}{h} \int_{(j-1)h}^h f(u) du$$

$$\text{Bias}(\hat{f}_h(m_j)) = \frac{1}{h} \int_{(j-1)h}^h f(u) du - f(x)$$

Esto se puede aproximar usando Taylor alrededor del centro  $m_j = jh - h/2$  de  $B_j$  de modo que  $f(u) - f(x) \approx f'(m_j)(u - x)$ .

$$\text{Bias}(\hat{f}_h(m_j)) = \frac{1}{h} \int_{(j-1)h}^h f(u) - f(x) du \approx f'(m_j)(m_j - x)$$

### 1.3.2 Varianza

Dado que todos los  $X_i$  son i.i.d., entonces

$$\begin{aligned}\text{Var}(\hat{f}_h(m_j)) &= \text{Var}\left(\frac{1}{nh} \sum_{i=1}^n I(X_i \in B_j)\right) \\ &= \frac{1}{n^2 h^2} n \text{Var}(I(X_i \in B_j))\end{aligned}$$

$$\begin{aligned}\text{Var}(\text{Ber}) \\ = p(1-p)\end{aligned}$$

La variable  $I$  es una bernoulli con parametro  $\int_{(j-1)h}^h f(u)du$  por lo tanto su varianza es el

$$\text{Var}(\hat{f}_h(x)) = \frac{1}{nh^2} \left( \int_{(j-1)h}^h f(u)du \right) \left( 1 - \int_{(j-1)h}^h f(u)du \right)$$

**Tarea 1.** Usando un desarrollo de Taylor como en la parte anterior, pruebe que

$$\text{Var}(\hat{f}_h(x)) \approx \frac{1}{nh} f(x)$$

## 2 Error cuadrático medio

El error cuadrático medio del histograma es el

$$\text{MSE}(\hat{f}_h(x)) = \text{E} \left[ \left( \hat{f}_h(x) - f(x) \right)^2 \right] = \text{Bias}^2(\hat{f}_h(x)) + \text{Var}(\hat{f}_h(x)).$$

**Tarea 2.** Pueden probar la segunda igualdad de la expresión anterior?

Retomando los términos anteriores se tiene que

$$\begin{aligned}\text{MSE}(\hat{f}_h(x)) &= \frac{1}{nh} f(x) + f'(x)^2 \left\{ (j-1/2)h - x \right\}^2 \\ &\quad + o(h) + o\left(\frac{1}{nh}\right)\end{aligned}$$

La fórmula anterior tiene la siguiente particularidad

- Si  $h \rightarrow 0$ , la varianza crece (converge a  $\infty$ ) y el sesgo decrece (converge a  $f'(0)x^2$ ).
- Si  $h \rightarrow \infty$ , la varianza decrece (hacia 0) y el sesgo crece (hacia  $\infty$ )

